

# Entrepôts de données

## Données, modélisation, intégration et analyse

NEGRE Elsa  
Université Paris-Dauphine  
2024-2025


# Contexte (1)

- Besoin :
  - Prise de décisions stratégiques et tactiques
  - Réactivité
- Qui :
  - les décideurs (non informaticiens, non statisticiens)
- Comment :
  - Répondre aux demandes d'analyse de données
  - Dégager des informations qualitatives nouvelles



# Contexte (2)

- Type de données : données opérationnelles (de production)
  - Bases de données, Fichiers, Paye, Gestion RH, ...
- Caractéristiques des données :
  - Distribuées : systèmes éparpillés
  - Hétérogènes : systèmes et structures de données différents
  - Détaillées : organisation de données selon les processus fonctionnels et données trop abondantes pour l'analyse
  - Peu/pas adaptées à l'analyse : des requêtes lourdes peuvent bloquer le système transactionnel
  - Volatiles : pas d'historisation systématique



# Problématique (1)


Nous avons donc :

- Une grande masse de données
  - Distribuées
  - Hétérogènes
  - Très détaillées
- à traiter
  - Synthétiser / résumer
  - Visualiser
  - Analyser
- pour une utilisation par des
  - Experts / analystes d'un métier
  - Non informaticiens
  - Non statisticiens

# Problématique (2)

- Comment répondre aux besoins de décideurs afin d'améliorer les performances décisionnelles de l'entreprise?
  - En donnant un accès rapide et simple à l'information stratégique
  - En donnant du sens aux données
  - En donnant une vision transversale des données de l'entreprise (intégration de différentes bases de données)
  - En extrayant, groupant, organisant, corrélant et transformant (résumé, agrégation) les données

# Problématique (3)



Mettre en place un SI dédié aux applications décisionnelles : un entrepôt de données (*datawarehouse*)

- Transformer des données de production en informations stratégiques




# Le processus de prise de décision (1)

## Business Intelligence (BI)


Moyens, outils et méthodes qui permettent à un décideur

- d'avoir une vue d'ensemble de l'activité traitée
- de trouver l'**information** pertinente et complète pour prendre rapidement la meilleure décision




# Données, Informations, Connaissances (1)

- **Comment**



# Données, Informations, Connaissances (2)

- Comment?




Business Intelligence : place de la BI et pilotage des projets décisionnels dans les grandes organisations françaises, October 2009,  
CIGREF

\*French power grid overall consumption January 2018


# BI (1)

- Evolution des analyses



# BI (2)


- Evolution des outils



# BI (3)

The diagram illustrates the progression from traditional Business Intelligence (BI) to Big Data Analytics. It features a central horizontal bar with two arrows pointing away from it. The left arrow points to the left and contains the text "BI traditionnelle". The right arrow points to the right and contains the text "Big Data Analytics". Below this diagram is a table comparing the two approaches across six categories.

	BI 1.0	BI 2.0	BI 3.0
Functionality	Present and Aggregate	Explore and Predict	Anticipate and Enrich
Frequency	Monthly/Detail	Weekly/Daily/Summary	Real-time/Process
Level of Focus	Community	Enterprise	Collaborative
Processing	Batch	Near Real-time	In-Process
Data Products	Information	Intelligence	Insight
Foundation/ Influence	Delivery Only	Creation + Delivery	Creation + Delivery + Automation




# SYSTÈME D'AIDE A LA DÉCISION – BI TRADITIONNELLE


Applications informatiques permettant de transformer les données opérationnelles en indicateurs pertinents dont la restitution guidera la prise de décision

# Architecture générale

Sources



S A D / DSS



Décideurs



Preparer /  
Intégrer

Stocker

Restituer /  
Présenter


# Les sources

# Données sources

- Caractéristiques
  - Volumineuses
  - Hétérogènes en contenu
  - Détaillées
  - Volatiles : pas d'histoirisation systématique ou incomplète (pour les analyses)
  - Peu ou pas adaptées à l'analyse
  
- Supports
  - Une ou plusieurs sources
  - Interne ou externe
  - Hétérogènes en modèles et systèmes de stockage

# ETL (1)

## Sources



# ETL (2)

- Modèle entité-relation (BD de production)  
→ Modèle à base de dimensions et de faits
- Outil :
  - Offrant un environnement de développement
  - Offrant des outils de gestion des opérations et de maintenance
  - Permettant de découvrir, analyser, et extraire les données à partir de sources hétérogènes
  - Permettant de nettoyer et standardiser les données
  - Permettant de charger les données dans un entrepôt

# ETL (3)


- But : Alimentation initiale et mise à jour périodique
- Outils pour automatiser ces différents chargements

# ETL (4) :

## Extraction, Transformation, Chargement

- ODS (Operational Data Store) / DSA (Data Staging Area)
  - Zones de stockage **non permanentes et optionnelles**

### Sources



## ■ Extraction :


- Depuis différentes sources (bd, fichiers, journaux, ...)
- Différentes techniques :
  - Push : règles (triggers)
  - Pull : requêtes (queries)
- Périodique et répétée
  - Dater ou marquer les données envoyées
- Difficulté :
  - Ne pas perturber les applications OLTP



## ■ Transformation : Etape très importante qui garantit la cohérence et la fiabilité des données

- Rendre cohérentes les données issues de différentes sources
  - Unifier les données
    - Ex. dates : MM/JJ/AA -> JJ/MM/AA
    - Ex. noms : D-Naiss, Naissance, Date-N -> « Date-Naissance »
  - Trier, Nettoyer
    - Eliminer les doubles
    - Jointures, projection, agrégation (SUM, AVG, ...)
    - Gestion des valeurs manquantes (NULL) (ignorer ou corriger ?)
    - Gestion des valeurs erronées ou inconsistantes (détecter et corriger)
    - Vérification des contraintes d'intégrité (pas de violation)
  - Inspection manuelle de certaines données possible...

## intégration des données




## ■ Chargement : Insérer ou modifier les données dans l'entrepôt

- Alimentation incrémentale ou totale?, offline ou online?, fréquence des chargements?, taille de l'historique?, ...
- Si pas de MAJ :
  - insertion de nouvelles données
  - Archivage des données anciennes
- Sinon (attention en cas de gros volumes)
  - Périodicité parfois longue
  - MAJ des indexés et des résumés

# Attention...


- ETL ≠ ELT
  - L'approche ELT (Extraction, Loading, Transformation) génère du code SQL natif pour chaque moteur de BD impliqué dans le processus – sources et cibles
  - Cette approche profite des fonctionnalités de chaque BD mais les requêtes de transformation doivent respecter la syntaxe spécifique au SGBD




# Le stockage (DW/DM)

# Stockage données décisionnelles


## Sources




Fichiers /  
Documents



BD interne



BD externes  
/ Internet



# L'entrepôt : Définition

- *Le DW est une collection de données orientées sujet, intégrées, non volatiles et historisées, organisées pour le support d'un processus d'aide à la décision.*

W.H. Inmon (1996)


- C'est une BD à des fins d'analyse !!

# L'entrepôt

- Objectif : Préparation des données décisionnelles
- Principe : Lieu de stockage centralisé d'un extrait des sources pertinent pour les décideurs, historisé, non volatile, disponible pour l'interrogation décisionnelle, organisé selon un modèle informatique facilitant la gestion des données

# Caractéristiques d'un DW (1)


- Données orientées sujet
  - Regroupe les informations des différents métiers
  - Ne tiens pas compte de l'organisation fonctionnelle des données



# Caractéristiques d'un DW (2)


## ■ Données intégrées

- Normalisation des données
- Définition d'un référentiel unique



# Caractéristiques d'un DW (3)

- Données non volatiles
  - Traçabilité des informations et des décisions prises
  - Copie des données de production



# Caractéristiques d'un DW (4)

## ■ Données historisées / datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps

Base de production

Image de la base en Mai 2005	
Répertoire	
Nom	Ville
Dupont	Paris
Durand	Lyon

Entrepôt de données

Calendrier		
Code	Année	Mois
1	2005	Mai
2	2006	Juillet

Image de la base en Juillet 2006

Répertoire

Nom	Ville
Dupont	Marseille
Durand	Lyon

Répertoire

Code	Année	Mois
1	Dupont	Paris
1	Durand	Lyon
2	Dupont	Marseille


# Caractéristiques d'un DW (5)

## ■ Inconvénient :

De par sa taille, le DW est rarement utilisé directement par les décideurs car il contient plus que nécessaire pour une classe de décideurs

# Le datamart

- Sous-ensemble d'un entrepôt de données
- Destiné à répondre aux besoins d'un secteur ou d'une fonction particulière de l'entreprise
- Point de vue spécifique selon des critères métiers



# Le datamart

- Objectif : Présentation des données décisionnelles
- Principe :
  - Extrait de l'entrepôt de données
  - Adapté aux besoins d'une classe de décideurs
  - Organisé selon un modèle informatique adapté aux outils décisionnels

# Pourquoi pas un SGBD ? (1)


- Fonctions d'un SGBD :
  - Systèmes transactionnels (OLTP)
  - Permettre d'insérer, modifier, interroger rapidement, efficacement et en sécurité les données de la base
  - Sélectionner, ajouter, mettre à jour, supprimer des tuples
  - Répondre à de nombreux utilisateurs simultanément

# Pourquoi pas un SGBD ? (2)

- Fonctions d'un DW :
  - Systèmes pour l'aide à la prise de décision (OLAP)
  - Regrouper, organiser des informations provenant de sources diverses
  - Intégrer et stocker les données pour une vue orientée métier
  - Retrouver et analyser l'information rapidement et facilement

# Pourquoi pas un SGBD ? (4)

OLTP: On-Line  
Transactional  
Processing



OLAP: On-Line  
Analytical  
Processing

# Pourquoi pas un SGBD ? (3)

	OLTP	DW
Utilisateurs	Nombreux Employés	Peu Analystes
Données	Alphanumériques Détaillées / atomiques Orientées application Dynamiques	Numériques Résumées / agrégées Orientées sujet Statiques
Requêtes	Prédéfinies	« one-use »
Accès	Peu de données (courantes)	Beaucoup d'informations (historisées)
But	Dépend de l'application	Prise de décision
Temps d'exécution	Court	Long
Mises à jour	Très souvent	Périodiquement

## Spreadsheets



### Pros

- « Easy to use »
- Many users trained
- Adapted to basic users
- Cheap
- Nice reporting graphics

### Cons

- No data management
- No query language
- No data control
- Reporting tool external (Word, Writer...)

## Databases



### Pros

- Excellent data management
- SQL = powerful language
- Adapted to “power users”

### Cons

- Technical
  - Understand storage models
  - Need to know SQL
- Mono-dimensional table display only
- No reporting graphics

## Olap Systems



### Pros

- Excellent data management
- Speed
- User-adapted query language
- Adapted to users and “power users”
- Nice reporting graphics
- Integrated reporting tool

### Cons

- Requires multidimensional modelling
- Expensive



# **MODÉLISATION MULTIDIMENSIONNELLE**

Niveau conceptuel

Niveau logique

Niveau physique

# Niveaux d'abstraction

## ■ Conceptuel

- Abstraction des aspects techniques
- Analyse des besoins des décideurs



## ■ Logique : Mode de stockage

## ■ Physique : Processus d'alimentation



# **NIVEAU CONCEPTUEL**

# Niveau conceptuel

- Description de la base multidimensionnelle indépendamment des choix d'implantation
- Les concepts:
  - Dimensions et hiérarchies
  - Faits et mesures

# Dimension (1)

- Axes d'analyse avec lesquels on veut faire l'analyse
  - Géographique, temporel, produits, etc.
- Chaque dimension comporte un ou plusieurs attributs/membres
- **Une dimension est tout ce qu'on utilisera pour faire nos analyses.**
- Chaque membre de la dimension a des caractéristiques propres et est en général textuel
- ***Remarque importante :***
  - Taille Dimension << Taille Fait

# Dimension (2)

Clé de substitution

Attributs de la dimension


Dimension produit
Clé produit (CP)
Code produit
Description du produit
Famille du produits
Marque
Emballage
Poids

# Hiérarchie (1)

- Les attributs/membres d'une dimension sont organisés suivant des hiérarchies
  - Chaque membre appartient à un niveau hiérarchique (ou niveau de granularité) particulier
  - Exemples :
    - Dimension temporelle : jour, mois, année
    - Dimension géographique : magasin, ville, région, pays
    - Dimension produit : produit, catégorie, marque, etc.
- Attributs définissant les niveaux de granularité sont appelés paramètres
- Attributs informationnels liés à un paramètre sont dits attributs faibles



# Hiérarchie (2)

## ■ Mono-hiérarchie




# Hiérarchie (3)

- Hiérarchies multiples dans une dimension (plusieurs hiérarchies alternatives pour une même dimension)



# Granularité

- Niveau de détail de représentation
  - Journée > heure du jour
  - Magasin > rayonnage
- Choix de la granularité



# Fait

- Sujet analysé
- un ensemble d'attributs appelés mesures (informations opérationnelles)
  - les ventes (chiffre d'affaire, quantités et montants commandés, volumes des ventes, ...)
  - les stocks (nombre d'exemplaires d'un produit en stock, ...),
  - les ressources humaines (nombre de demandes de congés, nombre de démissions, ...).
- Un fait représente la valeur d'une mesure, calculée ou mesurée, selon un membre de chacune des dimensions
- **Un fait est tout ce qu'on voudra analyser.**
  - Exemple : **250 000 euros** est un fait qui exprime la valeur de la mesure **Coût des travaux** pour le membre **2002** du niveau **Année** de la dimension **Temps** et le membre **Versailles** du niveau **Ville** de la dimension **Découpage administratif**.
- Le Fait contient les valeurs des mesures et les clés vers les dimensions

# Mesure

- Élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions.
- Ces valeurs sont le résultat d'opérations d'agrégation (SUM, AVG, ...) sur les données
  - Exemple :
    - Coût des travaux
    - Nombre d'accidents
    - Ventes
    - ...

# Clés

- Dimension
  - Clé primaire
- Fait
  - Clé composée
    - Clés étrangères des dimensions

# Modélisation


- Au niveau conceptuel, il existe 2 modèles :
  - en étoile (*star schema*)
  - ou en constellation (*fact constellation schema*)

# Modèle en étoile (1)


- Le fait au centre et des dimensions autour
- Les dimensions n'ont pas de liaison entre elles
- Avantages :
  - Facilité de navigation
  - Nombre de jointures limité
- Inconvénients :
  - Redondance dans les dimensions
  - Toutes les dimensions ne concernent pas les mesures

# Modèle en étoile (2)

## ■ Représentation graphique




# Modèle en étoile (3)




# Etoile - Formalisme graphique de Golfarelli (1)

## ■ Représentation d'une dimension



# Etoile - Formalisme graphique de Golfarelli (2)

## ■ Schéma en étoile




# Constellation (1)

- Série d'étoiles
  - Fusion de plusieurs modèles en étoile qui utilisent des dimensions communes
  - Plusieurs tables de fait et tables de dimensions, éventuellement communes

# Constellation (2)



# Constellation - Formalisme graphique de Golfarelli




# Démarche en 5 étapes (1)

## □ E1 : Définition de la structure du schéma

↳ Identification du fait ou des faits

↳ Identification des dimensions avec le niveau de granularité le plus bas



# Démarche en 5 étapes (2)

- E2 : définition détaillée du fait => Dictionnaire des mesures

*Besoins du décideur*

Code	Désignation	Type	Formule d'extraction
Qte_MD	Quantité mensuelle d'un produit vendu à un client	Entier	=...
Montant_MD	Montant de la vente d'un produit à un client, un mois donné	Réel	=...

*Liaison ED/BD source*

- E3 : définition détaillée des dimensions => Dictionnaire des attributs (cf. dictionnaire précédent)

# Démarche en 5 étapes (3)


- E4 : définition des hiérarchies (avec cardinalités)

↳ Connaissances métier : règles de gestion...

**Connaissance  
métier**

Chaque produit appartient à une seule gamme et  
chaque gamme appartient à un seul secteur

⇒ **Modélisation  
multidimensionnelle**




# Démarche en 5 étapes (4)


## □ E4 : définition des hiérarchies (suite)

↳ Analyse du schéma de la BD Source (ED ou BD de production)

### Schéma BD source



⇒ Modélisation  
multidimensionnelle



# Démarche en 5 étapes (5)



## □ E4 : définition des hiérarchies (suite)

↳ Analyse des valeurs de la BD Source (ED ou BD de production)

### Données BD source

Produit	CodeP	Secteur	Marque
	P1	S1	M1
	P2	S1	M1
	P3	S1	M2
	P4	S2	M3
	P5	S2	M4
	P6	S2	M4


### Ordonnancement



<= Modélisation  
multidimensionnelle

# Démarche en 5 étapes (6)

- E5 : définition complète du schéma conceptuel





# **NIVEAU LOGIQUE**

# Niveau logique

- Description de la base multidimensionnelle suivant la technologie utilisée :
  - ROLAP (*Relational-OLAP*)
  - MOLAP (*Multidimensional-OLAP*)
  - HOLAP (*Hybrid-OLAP*)

## □ Principles

- Outil Spécifique OLAP (requêteur graphique)

Virtuel

- Système de Gestion de Bases de Données OLAP

↳ Objectif : Interrogation performante

↳ Nouveau modèle pour améliorer les temps de réponse des requêtes

- *Données détaillées pour fait(s) et dimensions*
  - Redondance d'information
  - Limiter les jointures

Physique

- *Données agrégées contenant des pré-calculs*


↳ Solutions

- *R-OLAP (Relational-OLAP) : tables pour faits et dimensions*
- *M-OLAP (Multidimensional-OLAP) : un fichier contenant des matrices à plusieurs dimensions*
- *H-OLAP (Hybrid-OLAP) : tables pour les données détaillées et fichiers pour les données agrégées*

# ROLAP (1)

- Les données sont stockées dans une BD relationnelle
- Un moteur OLAP permet de simuler le comportement d'un SGBD multidimensionnel
- Avantages :
  - Facile à mettre en place
  - Peu coûteux
  - Evolution facile
  - Stockage de gros volumes
- Inconvénients :
  - Moins performant lors des phases de calculs
- Exemple de moteur ROLAP : Mondrian

# ROLAP (2)




# ROLAP (3)

- Principe : Faits et dimensions modélisés au travers de tables [Kimball 96]
- Règles de transformation (données détaillées)
  - R1 : Toute dimension est transformée en une relation où :
    - Attributs = tous les paramètres et attributs faibles
    - Clé primaire = paramètre de plus bas niveau
  - R2 : Tout fait est transformé en une relation où :
    - Clé primaire =
      - Concaténation des clés étrangères référençant les dimensions
      - OU
      - Clé synthétique
    - Attributs = mesures + clés étrangères

# MOLAP (1)

- Les données sont stockées comme des matrices à plusieurs dimensions : Cube[1:m,1:n,1:p](mesure)
- Accès direct aux données dans le cube
- Avantages :
  - Rapidité
- Inconvénients :
  - Difficile à mettre en place
  - Formats souvent propriétaires
  - Ne supporte pas de très gros volumes de données
- Exemple de moteurs MOLAP :
  - Microsoft Analysis Services
  - Hyperion

# MOLAP (2)



# HOLAP (1)

- Solution hybride entre ROLAP et MOLAP
- Données de base stockées dans un SGBD relationnel (tables de faits et de dimensions) + données agrégées stockées dans un cube
- Avantages / inconvénients :
  - Bon compromis au niveau des coûts et des performances (les requêtes vont chercher les données dans les tables et le cube)

# HOLAP (2)

HOLAP





table Employé			



# Synthèse

Type	R-OLAP	M-OLAP	H-OLAP
<b>Stockage données</b> <ul style="list-style-type: none"><li>Détaillées</li><li>Agrégées</li></ul>	Relations Relations	Cube Cubes (automatique)	Relations Cubes
<b>Avantages</b>	<ul style="list-style-type: none"><li>Facile à mettre en œuvre</li><li>Peu couteux</li><li>Evolution facile</li><li>Stockage gros volume de données</li></ul>	<ul style="list-style-type: none"><li>Rapidité de l'interrogation</li></ul>	Bon compromis au niveau des coûts et des performances
<b>Inconvénients</b>	<ul style="list-style-type: none"><li>Moins performant lors des interrogations (requêtes SQL)</li></ul>	<ul style="list-style-type: none"><li>Mise en place difficile</li><li>Formats propriétaire</li><li>Ne supporte pas de gros volume données</li><li>Coût licence élevé</li></ul>	
<b>Outils</b>	<ul style="list-style-type: none"><li>Microsoft Analysis Services de SQL Server</li><li>Oracle OLAP d'Oracle</li><li>Mondrian de Pentaho</li></ul>	<ul style="list-style-type: none"><li>IBM TM1</li><li>Oracle Essbase (ex. Hyperion)</li></ul>	Microsoft Analysis Services de SQL Server


# Modélisation

- Au niveau logique, il existe 1 modèle :
  - en flocon (*snowflake schema*)

# Modèle en flocon (1)

- Modèle en étoile + normalisation des dimensions
  - Un fait et des dimensions en sous-hiéronymies
  - Un seul niveau hiérarchique par « table » de dimension
  - La « table » de dimension de niveau hiérarchique le plus bas est reliée au fait (elle a la granularité la plus fine)
- Avantages :
  - Normalisation des dimensions
  - Economie d'espace disque (réduction du volume)
- Inconvénients :
  - Modèle plus complexe (nombreuses jointures)
  - Requêtes moins performantes
  - Navigation difficile

# Modèle en flocon (2)





# **NIVEAU PHYSIQUE**

# Niveau physique

- C'est l'implantation et dépend donc du logiciel utilisé.
- Globalement : insuffisance des instructions SQL classiques
  - CREATE TABLE ... AS ... : recopie physique, à reprendre intégralement lors de l'évolution des sources
  - CREATE VIEW ... AS ... : recalculé à chaque requête, temps de réponse inacceptable sur les volumes manipulés
- Optimisation : indexes, ...

# Quelques solutions commerciales



# Bilan – Niveaux d'abstraction

<b>Conceptuel</b>	<p><i>Schéma en constellation :</i></p> <ul style="list-style-type: none"> <li>- Fait(s) /Mesure(s)</li> <li>- Dimensions /Hiérarchies / Paramètres / Attributs faibles</li> </ul>				
	<b>Requêteur graphique</b>	<i>SGBD- stockage physique</i>			
<b>Logique</b>		<b>R-OLAP</b>		<b>M-OLAP</b>	<b>H-OLAP</b>
		<i>Dénormalisé</i>	Règles de traduction des faits et des dim.		Règles de traduction des faits et des dim.
		<i>Normalisé</i>	Règles de normalisation des dimensions		
		<i>Hybride</i>	Règles d'optimisation		
<b>Physique</b>	<i>Business Objects</i>		<i>Oracle</i>	<i>ETL OWB, Info. Server d'IBM...</i>	<i>Essbase IBM TM1</i>
	<i>Règles de traduction</i>		Commandes textuelles	Commandes graphiques	Commandes Textuelles ou graphiques
	Fait	Classe d'ind.	<ul style="list-style-type: none"> <li>- Create Materialized View (tables de detail ou vues auxiliaires)</li> <li>- Create Dimension</li> <li>- Alter Table</li> </ul>		
	Mesure	Indicateur			
	Dimension	Classe d'obj.			
	Paramètre	Dimension			
	Att. faible	Information			

# Realisation d'un DW

# Réalisation d'un DW

- Evolution des besoins et des sources  
→ démarche itérative
- 3 techniques :
  - Top-down [Inmon]
  - Bottom-up [Kimball]
  - Middle-out

## ■ Top-Down

- Concevoir tout l'entrepôt intégralement
  - Il faut donc connaître à l'avance toutes les dimensions et tous les faits.
- Objectif : Livrer une solution technologiquement saine basée sur des méthodes et technologies éprouvées des bases de données.
- Avantages :
  - Offrir une architecture intégrée : méthode complète
  - Réutilisation des données
  - Pas de redondances
  - Vision claire et conceptuelle des données de l'entreprise et du travail à réaliser
- Inconvénients :
  - Méthode lourde
  - Méthode contraignante
  - Nécessite du temps

## ■ Bottom-Up (approche inverse)

- Créer les datamarts un par un puis les regrouper par des niveaux intermédiaires jusqu'à obtention d'un véritable entrepôt.
- Objectif : Livrer une solution permettant aux usagers d'obtenir facilement et rapidement des réponses à leurs requêtes d'analyse
- Avantages :
  - Simple à réaliser,
  - Résultats rapides
  - Efficace à court terme
- Inconvénients :
  - Pas efficace à long terme
  - Le volume de travail d'intégration pour obtenir un entrepôt de données
  - Risque de redondances (car réalisations indépendantes).

## ■ Middle-Out (approche hybride)

- Concevoir intégralement l'entrepôt de données (toutes les dimensions, tous les faits, toutes les relations), puis créer des divisions plus petites et plus gérables.
- Avantages :
  - Prendre le meilleur des 2 approches
  - Développement d'un modèle de données d'entreprise de manière itérative
  - Développement d'une infrastructure lourde qu'en cas de nécessité
- Inconvénients :
  - implique, parfois, des compromis de découpage (duplicer des dimensions identiques pour des besoins pratiques).

# Ne pas oublier... (1)

## ■ Le volume de données manipulées

### Grandes distribution :

CA annuel : 80 000 M\$

Prix moyen d'un article d'un ticket : 5\$

Nbre d'articles vendus pour un an :  $80 * 10^9 / 5 = 16 * 10^9$

Volume du DW :

$$16 * 10^9 * 3 \text{ ans} * 24 \text{ octets} = \underline{\textcolor{red}{1,54 \text{ To}}} \quad (1,54 * 10^{12} = 1\,540 \text{ Go})$$

### Téléphonie :

Nbre d'appels quotidiens : 100 millions

Historique : 3 ans \* 365 jours = 1 095 jours

Volume du DW :

$$\textcolor{red}{100 \text{ millions} * 1\,095 \text{ jours} * 24 \text{ octets} = \underline{\textcolor{red}{3,94 \text{ To}}}}$$

### Cartes de crédit :

Nbre de clients : 50 millions

Nbre moyen mensuel de transactions : 30

Volume :

$$\textcolor{red}{50 \text{ millions} * 26 \text{ mois} * 30 \text{ transactions} * 24 \text{ octets} = \underline{\textcolor{red}{1,73 \text{ To}}}}$$

# Ne pas oublier... (2)


- Voici 5 étapes importantes pour la réalisation d'un DW :
  - Conception
  - Acquisition des données
  - Définition des aspects techniques de la réalisation
  - Définition des modes de restitution
  - Stratégies d'administration, évolution, maintenance

# 1 - Conception

- Définir la finalité du DW :
  - Quelle activité de l'entreprise faut-il piloter?
  - Quel est le processus de l'entreprise à modéliser?
  - Qui sont les décideurs?
  - Quels sont les faits numériques?
    - Qu'est ce qui va être mesurer?
  - Quelles sont les dimensions ?
    - Comment les gestionnaires décrivent-ils des données qui résultent du processus concerné?
- Définir le modèle de données :
  - Modèle en étoile / flocon ?
  - et/ou Cube?
  - et/ou Vues matérialisées?

## 2 – Acquisition des données

- Pour l'alimentation ou la mise à jour de l'entrepôt
  - Mise à jour régulière



Besoin d'un outil pour automatiser les chargements de l'entrepôt :

**ETL (*Extract, Transform, Load*)**

# 3 – Aspects techniques

## ■ Contraintes


- logicielles,
- matérielles,
- humaines,
- ...

# 4 - Restitution

- = But du processus d'entreposage,
- = Conditionne souvent le choix de l'architecture et de la construction du DW
- Toutes les analyses nécessaires doivent être réalisables !
  
- Types d'outils de restitution :
  - Requêteurs et outils d'analyse
  - Outils de data mining


# 5 – Administration, maintenance

- Toutes les stratégies à mettre en place pour l'administration, l'évolution et la maintenance
  - Ex : fréquences des rafraichissements (global ou plus fin?)



# Restitutions décisionnelles

## Décideurs



# Restitutions décisionnelles (1)

- Résultats
  - Différents supports possibles
    - Tableaux de bord : nombreux indicateurs pour pilotage avec tableaux récapitulatifs
    - Rapports d'activité : tableau simple ou croisé avec graphiques
    - Comptes-rendus : document avec de l'analyse décisionnelle, des données chiffrées (tableaux) et des graphiques
  - Contenu : global ou dédié

# Restitutions décisionnelles (2)

- Vision fonctionnelle
  - Consultation décisionnelle
  - Interrogation
    - Interrogation graphique
    - Interrogation à la demande (requêtes Ad-hoc en SQL/MDX)
  - Analyses personnelles
    - Format des restitutions : tableau, graphique, ...
    - Analyses : recherche particulière, analyse multidimensionnelle, simulation, ...
  - Analyses OLAP
    - Compétences en modélisation multidimensionnelle
    - Opérations OLAP (roll-up, slice, ...)
  - Analyse prédictive (datamining / machine learning)
    - Corrélations entre données
  - Outil pour un métier spécifique : RH, finance, ...


# Restitutions décisionnelles (3)

## 3 catégories d'outils

**GUIDED  
ANALYSIS &  
REPORTING**

**SELF-SERVICE BI**

**ADVANCED  
ANALYTICS**



# Restitutions décisionnelles (4)

## Restitutions décisionnelles : Editeurs logiciels

- **Géants**
  - IBM
  - SAP/BO
  - Oracle
  - Microsoft
- **Experts établis**
  - Microstrategy
  - SAS
  - Information Builders
- **Acteurs émergeants**
  - Leaders
    - Tableau
    - QlikTech
  - Visionnaires
    - Tibco
    - Sisense
  - Niche
    - Birst
    - Board
    - Yellowfin
    - Pentaho





# **REPRÉSENTATION ET MANIPULATION**


# Cube (1)

- Le cube de données
- est traditionnellement représenté sous forme de table multidimensionnelle
- et manipulé via différents opérateurs

# Cube (2)

- Modélisation multidimensionnelle des données facilitant l'analyse d'une quantité selon différentes dimensions :
  - Temps,
  - Localisation géographique,
  - ...
- Les calculs sont réalisés lors du chargement ou de la mise à jour du cube.

# Cube (3)






# Table multidimensionnelle (1)

## ■ La table multidimensionnelle

- Présente les valeurs des mesures d'un fait en fonction des valeurs des paramètres des dimensions représentées en lignes et en colonnes étant données des valeurs des autres dimensions
  - les lignes et les colonnes sont les axes selon lesquels le cube est exploré et chaque cellule contient la (ou les) mesure(s) calculée(s).
- correspond à une tranche du cube multidimensionnel

# Table multidimensionnelle (2)





Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
	Véhicules.AllV						

# Opérateurs OLAP

- Opérateurs de visualisation du cube (Cube -> Cube)
  - Transformation de la granularité des données (Forage)
  - Sélection / projection sur les données du cube
  - Restructuration / réorientation du cube

## ■ Opérations de forage (liées à la granularité)

### □ Roll-up (forage vers le haut) :

- Représente les données à un niveau de granularité supérieur selon la hiérarchie de la dimension désirée
  - Agréger selon une dimension
    - Semaine -> Mois

### □ Drill-down (forage vers le bas) :

- Inverse du roll-up
- Représente les données à un niveau de granularité inférieur
  - Détailler selon une dimension
    - Mois -> Semaine


Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.All							

Roll-Up



sur la dimension Géographie

Drill-down



Quantité des ventes		Géographie.Région	
		Aquitaine	Centre
Temps.Année	2005	2	551
	2006	2	782
	2007	5	944
	2008	4	925
Véhicules.All			

## ■ Opérations de sélection / projection

### □ Slice :



- Sélection
- Tranche du cube obtenue par prédictats selon une dimension
  - Mois = « Avril 2004 »

### □ Dice :

- Projection selon un axe
- Sorte de cumuls de sélection
  - Projeter(Région, Produit)

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AllV							


**Slice (Année = « 2005 »)**



Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	Véhicules.AllV						

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AllV							

Dice (Département = « Loir et Cher » ou « Gironde », Année = « 2007 » ou « 2008 »)



Quantité des ventes		Géographie.Département	
		Loir et Cher	Gironde
Temps.Année	2007	4	5
	2008	5	4
Véhicules.AllV			

## ■ Opérations de restructuration / réorientation

### □ Pivot (ou Rotate)

- Tourne le cube pour visualiser une face différente
  - (Région, Produit) -> (Région, Mois)

### □ Switch (ou Permutation)

- Inter-change la position des membres d'une dimension

### □ Nest

- Imbrique des membres issus de dimensions différentes

### □ Push (ou Enfoncement)


- Combine les membres d'une dimension aux mesures (les membres deviennent le contenu des cellules)

### □ AddM, DelM

- Pour l'ajout et la suppression de mesures à afficher

### □ ...

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AllV							




## Pivot

(Temps.Année, Géographie.Département  
-> Temps.Année, Véhicules.Couleur)

Quantité des ventes		Véhicules.Couleur			
		Blanc	Noir	Bleu	Rouge
Temps.Année	2005	120	200	150	83
	2006	130	220	150	284
	2007	140	250	259	300
	2008	150	280	249	250
Géographie.AllG					


Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AllV							



Nest (Véhicules.Couleur, Temps.Année)


Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Véhicules.Couleur	Temps.Année	2005	...	...	...	...	...
		2006	...	...	...	...	...
		2007	...	...	...	...	...
		2008	...	...	...	...	...
Blanc	Temps.Année	2005	...	...	...	...	...
		2006	...	...	...	...	...
		2007	...	...	...	...	...
		2008	...	...	...	...	...
Noir	Temps.Année	2005	...	...	...	...	...
		2006	...	...	...	...	...
		2007	...	...	...	...	...
		2008	...	...	...	...	...
Bleu	Temps.Année	2005	...	...	...	...	...
		2006	...	...	...	...	...
		2007	...	...	...	...	...
		2008	...	...	...	...	...
Rouge	Temps.Année	2005	...	...	...	...	...
		2006	...	...	...	...	...
		2007	...	...	...	...	...
		2008	...	...	...	...	...

Quantité des ventes		Géographie.Département					
		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
Temps.Année	2005	100	200	100	150	1	2
	2006	250	210	120	200	2	2
	2007	260	230	250	200	4	5
	2008	280	220	220	200	5	4
Véhicules.AllV							



## Push (Véhicules.Couleur)

Quantité des ventes		Géographie.Département					
Temps.Année		Loiret	Eure et Loir	Indre	Indre et Loire	Loir et Cher	Gironde
2005	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...
	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...
	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...
	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...
2006	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...
	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...
	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...
	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...
2007	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...
	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...
	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...
	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...
2008	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...	Blanc ...
	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...	Noir ...
	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...	Bleu ...
	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...	Rouge ...



# Bilan

# BI traditionnelle

- Avantages :
  - Données : consolidées, unifiées, historisées
  - Analyses / restitutions faciles
  - Solution mature
  - Très adaptée aux données structurées voire semi-structurées
- Inconvénients :
  - Travail en amont conséquent (80% du temps et du coût) : analyse, conception, déploiement et maintenance
  - Infrastructures coûteuses : nombreux outils à combiner
- Caractéristiques :
  - Forte implication des services IT
  - Large panel d'analyses : tableaux de bord prédefinis mis à disposition jusqu'à la BI en « self-service »

# Quelques solutions Open source

ETL	Entrepôt de données	OLAP	Reporting	Data Mining
<ul style="list-style-type: none"><li>■ Octopus</li><li>■ Kettle</li><li>■ CloverETL</li><li>■ Talend</li></ul>	<ul style="list-style-type: none"><li>■ MySql</li><li>■ Postgresql</li><li>■ Greenplum/Bizgres</li></ul>	<ul style="list-style-type: none"><li>■ Mondrian</li><li>■ Palo</li></ul>	<ul style="list-style-type: none"><li>■ Birt</li><li>■ Open Report</li><li>■ Jasper Report</li></ul>	<ul style="list-style-type: none"><li>■ Weka</li><li>■ R-Project</li><li>■ Orange</li><li>■ Xelopes</li></ul>
■ JFreeReport				
Intégré				
<ul style="list-style-type: none"><li>■ Pentaho (Kettle, Mondrian, JFreeReport, Weka)</li><li>■ SpagoBI</li></ul>				

# BI 3.0

BI 3.0	
Functionality	Anticipate and Enrich
Frequency	Real-time/Process
Level of Focus	Collaborative
Processing	In-Process
Data Products	Insight
Foundation/ Influence	Creation + Delivery + Automation

## Big Data Analytics?

# **DATA LAKE**

# Data Lake : Lac de données (1)

- Emplacement **unique** et **centralisé** permettant de stocker et de gérer à **bas coût** de fortes volumétries de données structurées, semi-structurées et non structurées, dans leur **format natif** à mesure qu'elles arrivent. **Les données stockées n'ont pas vocation à être modélisées.**




# Data Lake : Lac de données (2)

- Principe : Pas de connaissance *a priori* des besoins d'analyse
- Définition :

Un Data lake permet de :

- Intégrer les données brutes provenant de diverses sources
  - Données structurées provenant de BD relationnelles (BD production, entrepôts, ...)
  - Données semi-structurées : CSV, logs, XML, JSON
  - Données non structurées : emails, documents, PDF, ...
- Stocker les données dans leur format natif avec des technologies à faible coût
- Traiter les données uniquement lorsqu'elles sont utilisées
- Fournir des accès à des data scientists, data analysts et BI professionals
- Gérer la qualité des données, la sécurité des données et le cycle de vie des données

# Data Lake : Lac de données (3)




# Data Lake : Lac de données (4)

Aspects	Data warehouse	Data lake
<b>Schema</b>	Schema on-write	Schema on-read
<b>Data</b>	Structured, processed	Structured Semi-structured Unstructured
<b>Data scale</b>	A large volume of data	A larger volume of data
<b>Metadata</b>	Optional	Essential
<b>Complexity</b>	Complex integration	Complex processing
<b>Flexibility</b>	Low (fixed configuration)	High (configure and reconfigure as needed)
<b>User</b>	BI Professional	BI Professional Data scientist Data statistician
<b>Cost</b>	High (hardware, software, human resources)	Low
<b>Design</b>	Data and ETL process design : long, complex	NO
<b>Security</b>	Mature	Maturing

# Data Lake : Architecture fonctionnelle (1)


- Multi-zones : 5 zones de base

All types of data are ingested, with the help of metadata tags, without processing.



# Data Lake : Architecture fonctionnelle (2)

## Autre variante



# Data Lake : Architecture fonctionnelle (3)

- Autre variante

Data lake reference architecture




# Data Lake : Bilan (1)

- Avantages :
  - Pas de connaissance des besoins au préalable
  - Pas de conception initiale des schémas de données
  - Intégration de grands volumes de données
  - Intégration de tous types de données
- Inconvénients :
  - Solution non mature (concept et architecture fonctionnelle)
  - Infrastructures matérielles très (trop?) variées
  - Phase d'analyse et de restitution fastidieuses
- Caractéristiques :
  - S'adresse à un public de plus en plus large
  - Large panel d'analyses : reporting, interrogation, Machine learning, ...


# Data Lake : Bilan (2)

## Eviter le marécage



# Data Lake : Bilan (3)

- Data Lake et Entrepôt sont complémentaires





# **LES OUTILS BI 3.0**

# Les outils BI 3.0 (1)

## ■ Constat

- Croissance des volumes de données disponibles :
  - 2018 : volume total stocké (monde entier) = 33 zettaoctets.
  - D'ici 2025 : multiplié par 5,3 = 175 Zo = 175 milliards de téraoctets.
- 90% sont constitués d'images, de vidéo et de musique : majoritairement des données « non structurées » et hétérogènes
- Ces données sont difficilement traitables avec les techniques classiques

# Les outils BI 3.0 (2)

## ■ Besoins :

- Technologies pour acquérir, stocker, combiner et diffuser des mégadonnées (Big Data) : variées, véloces, volumineuses, ...
- Effectuer des analyses, en (quasi) temps réel sur des Big Data de manière itérative
- Supporter la collaboration

## ■ Nouvelles technologies émergentes :

- Hadoop, Map Reduce, ...
- DataViz avancée,

# Big Data Technology

BIG DATA & AI LANDSCAPE 2018



# Ouvrages intéressants (disponibles à la BU)

- « Data Warehouse Design: Modern Principles and Methodologies » de Matteo Golfarelli et Stefano Rizzi, 2009, Ed: Osborne/McGraw-Hill.
- « Olap Solutions: Building Multidimensional Information Systems » de E. Thomsen, 2002, Ed: John Wiley & Sons Inc.
- « The enterprise big data lake delivering the promise of big data and data science » de A. Gorelik, 2019, Ed: iO'Reilly Media

# Exercice

On considère un entrepôt de données permettant d'observer les ventes de produits d'une entreprise. Le schéma des tables est le suivant :

- *CLIENT (id-client, région, ville, pays, département)*
- *PRODUIT (id-prod, catégorie, coût-unitaire, fournisseur, prix-unitaire, nom-prod)*
- *TEMPS (id-tps, mois, nom-mois, trimestre, année)*
- *VENTE (id-prod, id-tps, id-client, date-expédition, prix-de-vente, frais-de-livraison)*

## Questions

1. Indiquer quels sont le(s) fait(s) et les dimensions de cet entrepôt.
2. Donner pour chaque dimension, sa (multi-) hiérarchie.
3. Donner la représentation du schéma en étoile de l'entrepôt selon la notation de Golfarelli.
4. On veut transformer ce schéma en étoile en schéma en flocon.  
Donner la nouvelle représentation de TEMPS (ajouter des paramètres / attributs, si nécessaire)